长短期记忆模型 -- LSTM

一. 提出背景

简单的rnn在应用中会有许多缺陷:

- 不支持**长期依赖(Long-term Dependeny)**, `The animal didn't cross the street because it was too tired.` 中的 `it` 指的是 `animal`, 但是由于相距过长 (时间步较长), *梯度消失*使得简单rnn很难记住这个关系
- **序列数据的一些词元没有观测值**(和目标无关), rnn无法跳过. 对网页内容情感分析时, 一些辅助HTML代码与网页内容传达的情绪无关, 能否**有一些机制来跳过隐状态表示中的此类词元**
- ...

综上, 引入**门控机制**, 网络能够通过专门的门控来决定隐状态的更新和重置(信息的忘记与保留). 例如, 如果第一个词元非常重要, 模型将学会在第一次观测之后不更新隐状态. 同样, 模型也可以学会跳过不相关的临时观测. 最后, 模型还将学会在需要的时候重置隐状态。

二. "后提出,更简单"的门控网络 -- GRU

学习LSTM之前, 先学习较简单的门控循环单元(Gated recurrent unit), 便于理解门控机制

1. 结构总览

$sigmoid$函数值区间为$(0,1)$, 有"比例"的作用, 可以用做阀门
[门的值要与把关的数据做Hadamard乘($\odot$)]

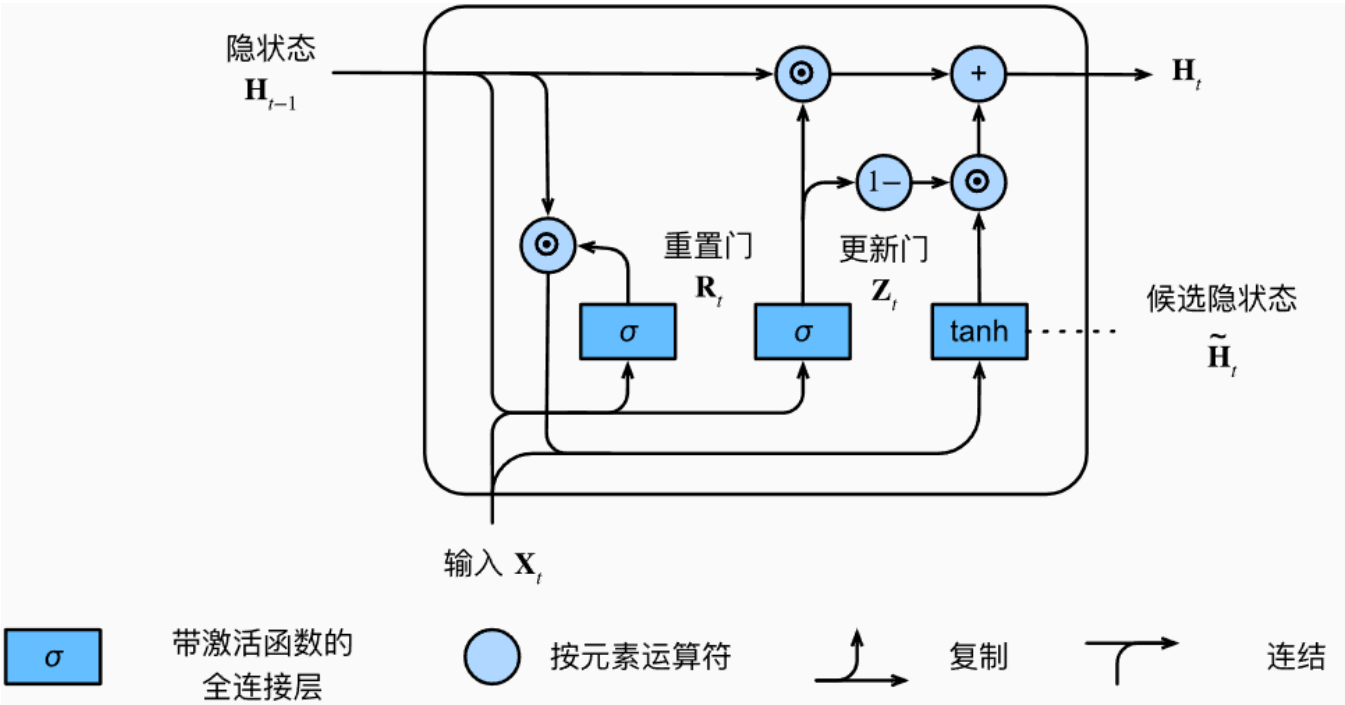

2. 数学表达

对于给定的时间步t，假设输入是一个小批量$X_t \in R^{n\times d}$（样本个数n，输入个数d），上一个时间步的隐状态是$H_{t-1} \in R^{n\times h}$（隐藏单元个数$h$）。
那么，重置门$R_t \in R^{n\times h}$和更新门$Z_t \in R^{n\times h}$的计算如下所示：

$$R_t = \sigma(X_t W_{xr} + H_{t-1} W_{hr} + b_r)$$
$$Z_t = \sigma(X_t W_{xz} + H_{t-1} W_{hz} + b_z)$$

进而计算**候选隐状态**$\tilde{H}$:

$$\tilde{H}_t = \tanh\left(X_t W_{xh} + \left(R_t \odot H_{t-1}\right) W_{hh} + b_h\right)$$

与简单rnn的 *cell处理* 对比, R_t与H_{t-1}相乘可以减少以往状态的影响, 每当重置门R_t中的项接近1时, 即为简单的rnn; 对于R_t中所有接近0的项, 候选隐状态可以看作X_t作为输入的MLP的结果, 即清空了以前的记忆.

接下来利用**更新门**Z_t得到真正的**隐状态**H_t:

$$H_t = Z_t \odot H_{t-1} + (1 - Z_t) \odot \tilde{H}_t$$

[H_{t-1}表示上一个时间步的隐状态], 每当更新门Z_t接近1时, 模型**倾向于只保留旧状态**H_{t-1}, 此时来自X_t的信息基本被忽略

3. 门的理解

GRU 用到了两个门:

- *重置门(reset gate)*: 控制"可能还想起"的过去状态的数量;
- *更新门(update gate)*: 控制新状态中有多少个是旧状态的副本.

重置门和更新门各司其职。重置门单方面控制自某个节点开始，之前的记忆（隐状态）不在乎了，*直接清空影响*，同时也需要更新门帮助它实现记忆的更新。更新们更多是用于*处理梯度消失问题*，可以选择一定程度地保留记忆，防止梯度消失。

- *重置门*有助于捕获序列中的**短期依赖**关系;
- *更新门*有助于捕获序列中的**长期依赖**关系.

三. 长短期记忆模型 -- LSTM

LSTM引入了*记忆元(memory cell)*, 记忆元是隐状态的一种特殊类型
为了控制记忆元, 需要很多门:

- *输出门(output gate)* 从单元中输出记忆元的tanh的门控版本;
- *遗忘门(forget gate)* 用于重置单元的内容;
- *输入门(input gate)* 用于控制写入多少新数据

1. 结构

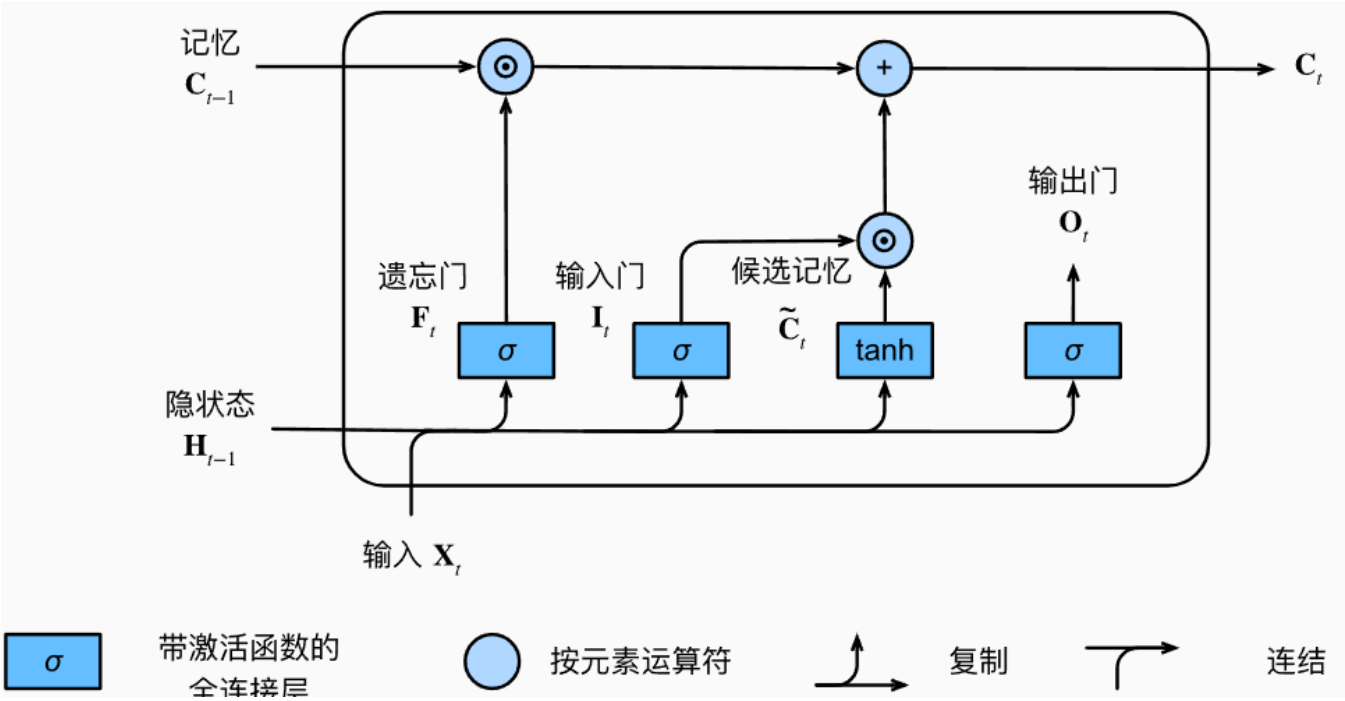

2. 数学表达

假设有h个隐藏单元, 批量大小是n, 输入数为d.
输入$X_t \in R^{n\times d}$, 前一时间步的隐状态为$H_{t-1} \in R^{n\times d}$, 三个门的值为:

$$
\begin{aligned}
I_t &= \sigma\left(X_t W_{xi} + H_{t-1} W_{hi} + b_i\right) \\
F_t &= \sigma\left(X_t W_{xf} + H_{t-1} W_{hf} + b_f\right) \\
O_t &= \sigma\left(X_t W_{xo} + H_{t-1} W_{ho} + b_o\right)
\end{aligned}
$$

候选记忆元类似简单rnn在某一时间步的输出:

$$
\tilde{C}_t = \tanh\left(X_t W_{xc} + H_{t-1} W_{hc} + b_c\right)
$$

最后新的记忆元C_t计算为通过遗忘门和输入门的数据总和:

$$
C_t = F_t \odot C_{t-1} + I_t \odot \tilde{C}_t
$$

输出门的作用就是计算隐状态$H_t \in R^{n\times h}$, 该隐状态会传递到输出层:

$$H_t = O_t \odot \tanh(C_t)$$

这里的$\tanh$用于将C_t的值重新映射到$(-1,1)$, 只要输出门接近1, 我们就能够有效地将所有记忆信息传递给预测部分, 而对于输出门接近0, 我们只保留记忆元内的所有信息, 而不需要更新隐状态.

3. 门的理解

LSTM循环网络中, 可以把记忆元C这条看作是**一本"日记本"的更新**, 将**遗忘门F_t视作是"橡皮"**, 他能够"擦除"过去C_{t-1}上过去的一部分; 可以将**输入门I_t视作是"铅笔"**, 他控制要把多少新的内容$\tilde{C}_t$写到笔记本上.

四. LSTM的BPTT, 缓解梯度消失

对于LSTM的相关公式:

$$\begin{cases} F_t = \sigma\left(W_{xf}X_t + U_{hf}H_{t-1} + b_f\right) \\ I_t = \sigma\left(W_{xi}X_t + U_{hi}H_{t-1} + b_i\right) \\ O_t = \sigma\left(W_{xo}X_t + U_{ho}H_{t-1} + b_o\right) \\ \tilde{C}_t = \tanh\left(W_{xc}X_t + U_{hc}H_{t-1} + b_c\right) \\ C_t = F_t \odot C_{t-1} + I_t \odot \tilde{C}_t \\ h_t = O_t \odot \tanh\left(C_t\right) \end{cases}$$

链式法则推导参数偏导时, 会出现$\prod_{j=k+1}^{t} \frac{\partial C_j}{\partial C_{j-1}}$这样的偏导, 有上面公式可知,

$$\frac{\partial C_j}{\partial C_{j-1}} = F_t$$

因为$F_t = \sigma(...)$, 所以F_t的范围是$(0,1)$
实际中, $F_t \approx 1$, 故**连乘后几乎不衰减**.