自然语言处理 (NLP) 入门

在开始rnn这些语言模型时, 对基本的序列信息, 语言模型的数据集形式缺乏认知, 故在此进行一些 NLP 有关的入门学习

一. 语言模型的数据形式

1. 原始数据

原始数据就是文本, 比如 `I love deeping learning` , 或者是一篇文章 `deepinglearn.txt` :

```
I love machine learning
Deep learning is powerful
Natural language processing is interesting
```

2. 文本 --> 数字序列

语言模型对文本的第一个**预处理**是--**分词(Tokenization)**

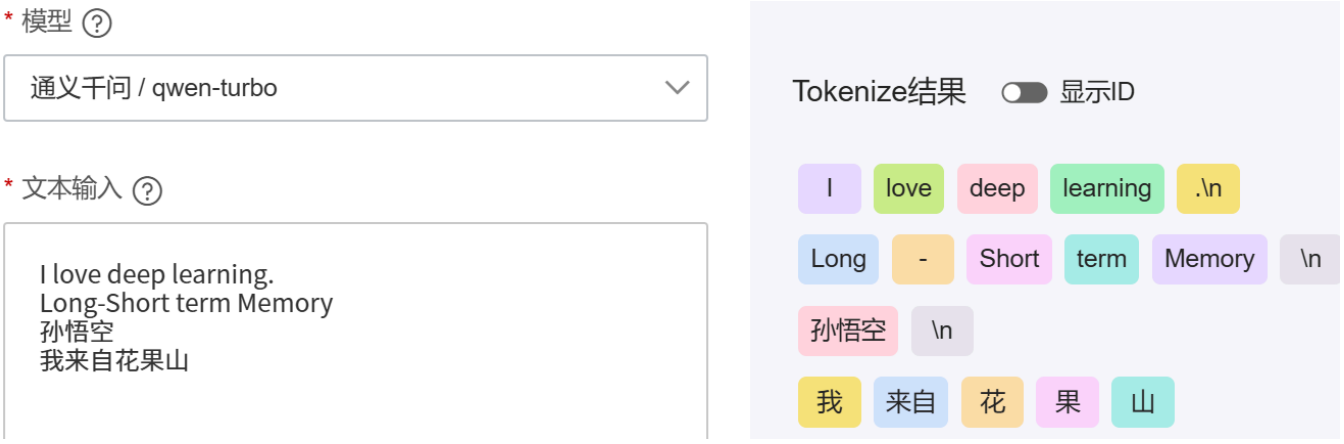

可以将 `I love deep learning` 分为**若干个词元(token)**:

```
["I", "love", "deep", "learning"]
```

通过给每个词分配id, 就能建立词表, 进行文本句子就变成数字序列:

```
[1, 2, 3, 4]
```

3. Embeding (词向量)

Word Embedding就是为了解决one-hot编码的缺陷, 其用一个向量来对一个词进行表示. 具有很强的表达关联特征的能力
输入token id后, 还要转向量 [$token \in R^n$转为$vector \in R^{n \times d}$]:

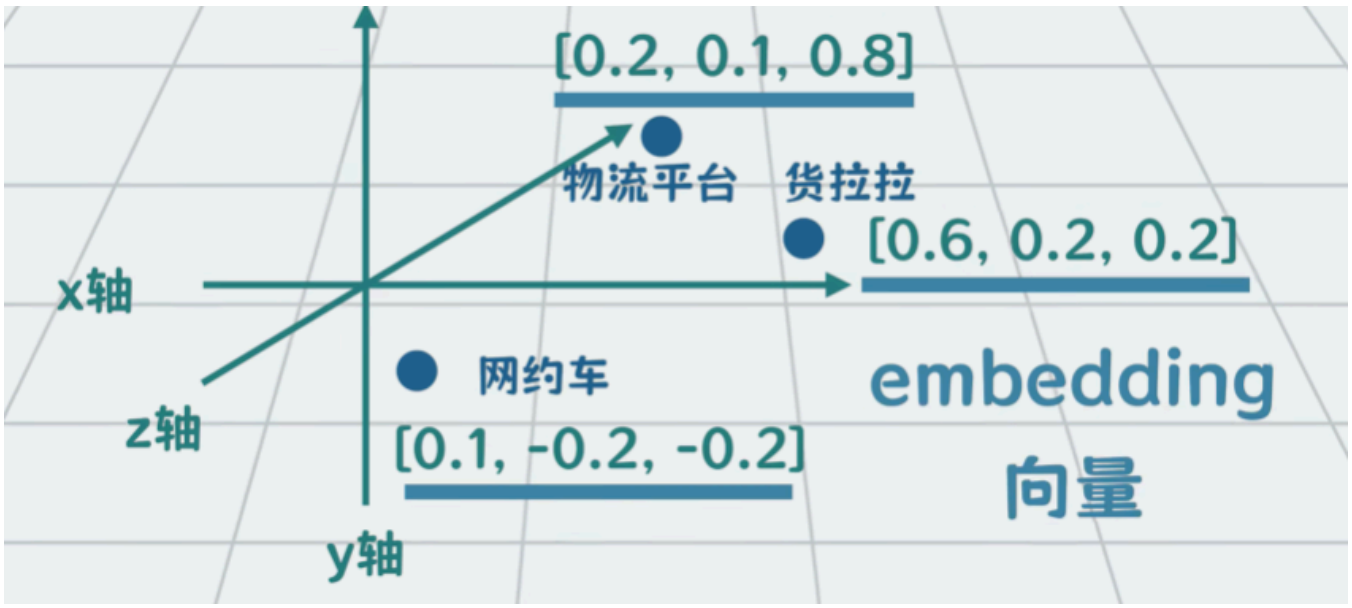

Embedding层最终完成的工作：

1. 将稀疏矩阵 (one-hot) 经过线性变换（查表）变成一个密集矩阵
2. 这个密集矩阵用了**N个特征(`embeddings_dim`)来表示所有的词**。密集矩阵中表象上是一个词和特征的关系系数，实际上蕴含了大量的词与词之间的内在关系。
3. 它们之间的权重参数，用的是**嵌入层学习来的参数**进行表征的编码。在神经网络反向传播优化的过程中，这个参数也会不断的更新优化。

```
self.embedding = nn.Embedding(num_embeddings=vocab_size, embedding_dim=embedding_dim)
# embedding层暗含权重矩阵形状为(num_embeddings, embeddings_dim)
# 他能将接收的输入的每一个token变换成一个word vector
# (batch, seq_len) ==> (batch, seq_len, embedding_dim)
```

embedding内部的可学习矩阵$shape = (vocab_size, embedding_dim)$, 意思是词表(vocab)的每一个token id都有$embedding_dim$个特征

二. 语言模型(LM)的任务

语言模型的目标就是根据前面的文本去**预测下一个词**
假设长度为T的文本序列中的词元依次为$x_1, x_2, ..., x_T$, $x_t(1 \leq t \leq T)$, x_t可以认为是**文本序列在时间步t处的观测或标签**, 在给定这样的文本序列时, *语言模型(LM)*的目标就是**估计**序列的联合概率:

$$P(x_1, x_2, ..., x_T)$$

1. 训练数据

- 输入:
  `[1, 2, 3]`
- 目标(target):
  `[2, 3, 4]`

1. **RNN 的 `next-token prediction`**

```
t=1: input=I        predict=love
t=2: input=love     predict=deep
t=3: input=deep     predict=learning
```

2. **实际的batch数据**

```
sentence1: I love deep learning
sentence2: deep learning is fun

token:
[1,2,3,4]
[3,4,5,6]
```

3. batch训练

```
输入:              目标:
[[1,2,3],          [[2,3,4],
 [3,4,5]]           [4,5,6]]
```

2. 不同NLP任务的数据形式

任务	输入	输出
语言模型	单词序列	下一个词
情感分析	句子	正/负
机器翻译	英文句子	中文句子
问答	问题+文章	答案

3.一个关键理解

RNN的**本质建模**就是:

$$P(x_t|x_1...x_{t-1})$$

这适用于各种序列数据:

数据	序列
文本	单词
语音	声音帧
股票	时间点
视频	图像帧

1. NLP 数据本质就是整数序列:
   `[35, 81, 9, 104, 6]`
2. 模型的任务就是:
   `predict next number`
3. 这些数字背后的代表:
   `words, 时间点, 图像帧, ...`