注意力机制 (attention mechanism)

*Attention*是一种计算机制, Transformer的核心计算模块就是*Self-Attention(自注意力)*

一. 注意力汇聚

人们基于*非自主性提示*和*自主性提示*有选择的引导注意力的焦点.

1. **非自主提示**是来自**环境**中物体的突出性和易见性(醒目的颜色, 尖叫声);
2. **自主性提示**来自**人的主观意识**, 比如在杂乱的环境中, 专注于黑白打印的书本文字.

用神经网络来设计注意力机制的框架的话:

1. 若只有非自主提示, 则可以简单的使用参数化的全连接层, 甚至是非参数化的最大汇聚层或平均汇聚层就能实现
2. 若要包含注意力机制, 简单的全连接层就不行了

1. 自主性提示 -- 查询(query)

自主性提示被称为*查询(query)*, 给定查询, *注意力汇聚(attention pooling)* 将查询与接近的*键(key, 代表非自主性提示)* 匹配, 从而将注意力导向到以key相配对的 *值(value, 感官输入)*

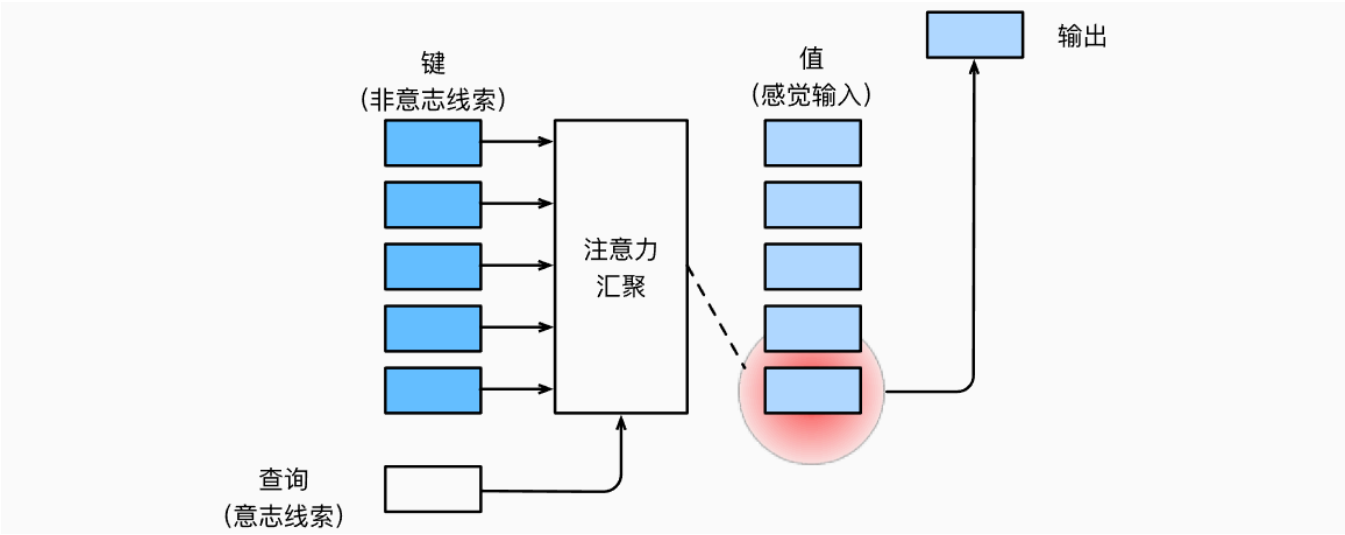

2. 无参数注意力汇聚

考虑一个回归问题: 给定的成对的"输入-输出"数据集$(x_1, y_1), (x_2, y_2), ..., (x_n, y_n)$, 如何学习

出f来预测任意的新输入x的输出$\hat{y} = f(x)$?

可以使用**加权注意力**, 通过输入x和以往输出x_i的相关性, 来给相应的y_i加权:

$$f(x) = \sum_{i=1}^{n} \frac{K(x - x_i)}{\sum_{j=1}^{n} K(x - x_j)} y_i$$

对于任意查询, 模型在所有键值对注意力权重都**是一个有效的概率分布**.

无参数的注意力汇聚, 只要有足够的数据, 模型确实能够收敛到最有效果

3.带参数注意力汇聚

在上述无参数模型中, 加入可学习的参数集
[采用高斯核$K(x - x_i) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{(x-x_i)^2}{2}\right)$]:

$$\begin{aligned} f(x) &= \sum_{i=1}^{n} \alpha(x, x_i) y_i \\ &= \sum_{i=1}^{n} \frac{\exp\left(-\frac{1}{2}\left((x - x_i)w\right)^2\right)}{\sum_{j=1}^{n} \exp\left(-\frac{1}{2}\left((x - x_j)w\right)^2\right)} y_i \\ &= \sum_{i=1}^{n} \operatorname{softmax}\left(-\frac{1}{2}\left((x - x_i)w\right)^2\right) y_i. \end{aligned}$$

二. 注意力评分函数

将注意力汇聚模块进行细分, 可以得到:

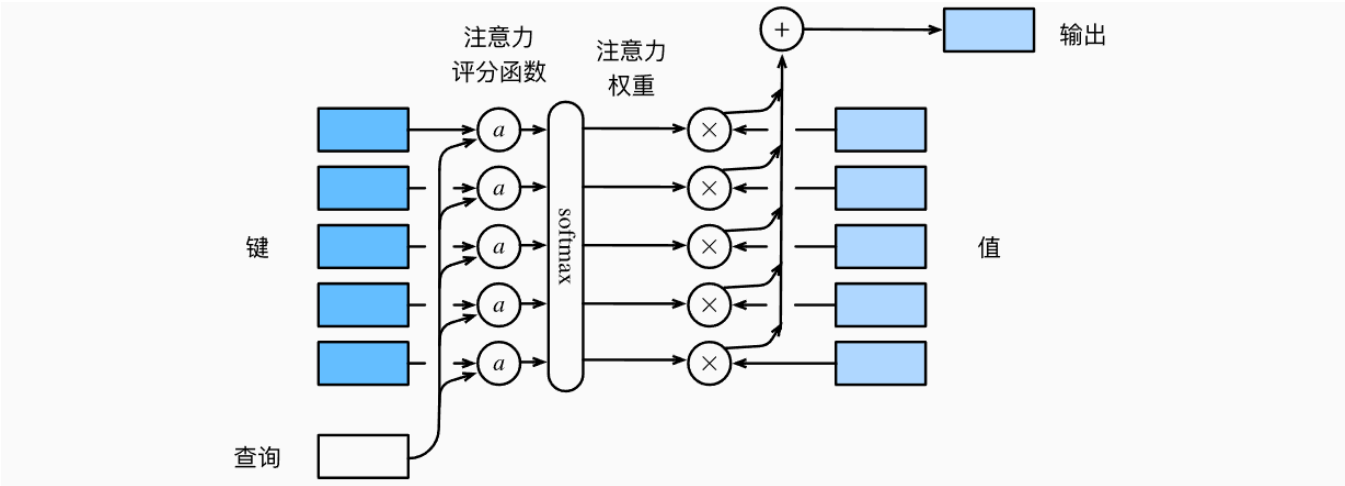

有一个查询$q \in R^q$和m个"键-值"对$(k_1, v_1), ..., (k_m, v_m)$, 其中$k \in R^, v_i \in R^v$, **注意力汇聚函数f**就被表示为值的加权平均:

$$f(q, (k_1, v_1), ..., (k_m, v_m)) = \sum_{i=1}^{m} \alpha(q, k_i) v_i$$

其中查询q和键k_i的注意力权重 (标量) 是通过注意力评分函数$score$将两个向量映射成标量, 在经过softmax运算的得到的:

$$\alpha(\mathbf{q}, \mathbf{k}_i) = softmax(score(\mathbf{q}, \mathbf{k}_i)) = \frac{\exp(score(\mathbf{q}, \mathbf{k}_i))}{\sum_{j=1}^{m} \exp(score(\mathbf{q}, \mathbf{k}_j))}$$

注意力评分的得分就代表这个q和键k_i之间的相关性

1. softmax mask -- 指定有效长度

$softmax$操作输出一个概率分布作为注意力权重, 默写情况下, 并非所有的值都应该被纳入到注意力汇聚中, 为了仅将**有意义的词元作为值**来获取注意力汇聚, 可以制定一个$validlength$有效序列长度(即词元的个数), 以便在计算softmax时过滤掉超出指定范围的位置
实现masked-softmax函数, 源码在attention.masked_softmax()

三. 两个注意力模型

1. 加性注意力

当**查询和键是不同长度的矢量**时, 可以使用*加性注意力(additive attention)* 作为评分函数, 给定查询$q \in R^q$和键$k \in R^k$, 加性注意力的评分函数为

$$score(\mathbf{q}, \mathbf{k}) = \mathbf{w}_v^\top \tanh\left(W_q\mathbf{q} + W_k\mathbf{k}\right) \in \mathbb{R}$$

其中**可学习的参数**是$W_q \in R^{h\times q}$, $W_k \in R^{h\times k}$, 和$w_v \in R^v$. 将查询和键连结起来后输入到一个多层感知机(MLP), 感知机包含一个隐藏层, 其隐藏单元数(hidden_size)是一个超参数h. 使用$\tanh$作为激活函数, 并且禁用偏置项

2. 缩放点积注意力

使用**点积**可以得到计算效率更高的评分函数, 但是点积操作要求**查询和键具有相同的长度**d.
从小批量的角度来考虑提高效率, 基于n个查询$\mathbf{Q}$和m个键值$\mathbf{K}$对计算注意力, 其中查询和键的长度为d, 值的长度为v, 查询$\mathbf{Q} \in R^{n\times d}$, 键$\mathbf{K} \in R^{m\times d}$, 和值$\mathbf{V} \in R^{m\times v}$的 *缩放点积注意力(scaled dot-product attention)* 是:

$$socre(Q, K) = \frac{QK^\top}{\sqrt{d}}$$

$$\operatorname{softmax}\left(\frac{QK^\top}{\sqrt{d}}\right)V \in \mathbb{R}^{n\times v}$$

```python
class DotProductAttention(nn.Module):
    """Scaled Dot-product Attention"""
    def __init__(self, dropout, **kwargs):
        super(DotProductAttention, self).__init__(**kwargs)
        self.dropout = nn.Dropout(dropout)

    # query的形状: (batch_size, 查询个数, d)
    # keys的形状: (batch_size, "键值对"个数, d)
    # values的形状: (batch_size, "键值对"个数, 值的维度)
    # valid_lens的形状: (batch_size, ) 或者(batch_size, 查询个数)

    def forward(self, queries, keys, values, valid_lens=None):
        d  = queries.shape[-1]
        # 设置transpose_b=True为了交换keys的最后两个维度(即batch_size里面一个一个转置)
        scores = torch.bmm(queries, keys.tanspose(1, 2))/ math.sqrt(d)
        self.attention_weights = masked_softmax(scores, valid_lens)
        return torch.bmm(self.dropout(self.attention_weights),values)
```

(1) 缩放因子--$\sqrt{d}$

1. 如果d很小, *additive attentiton*和*dot-product attention*相差不大
2. 如果d很大, 点乘的值很大, 如果不做$scaling$, 结果就没有

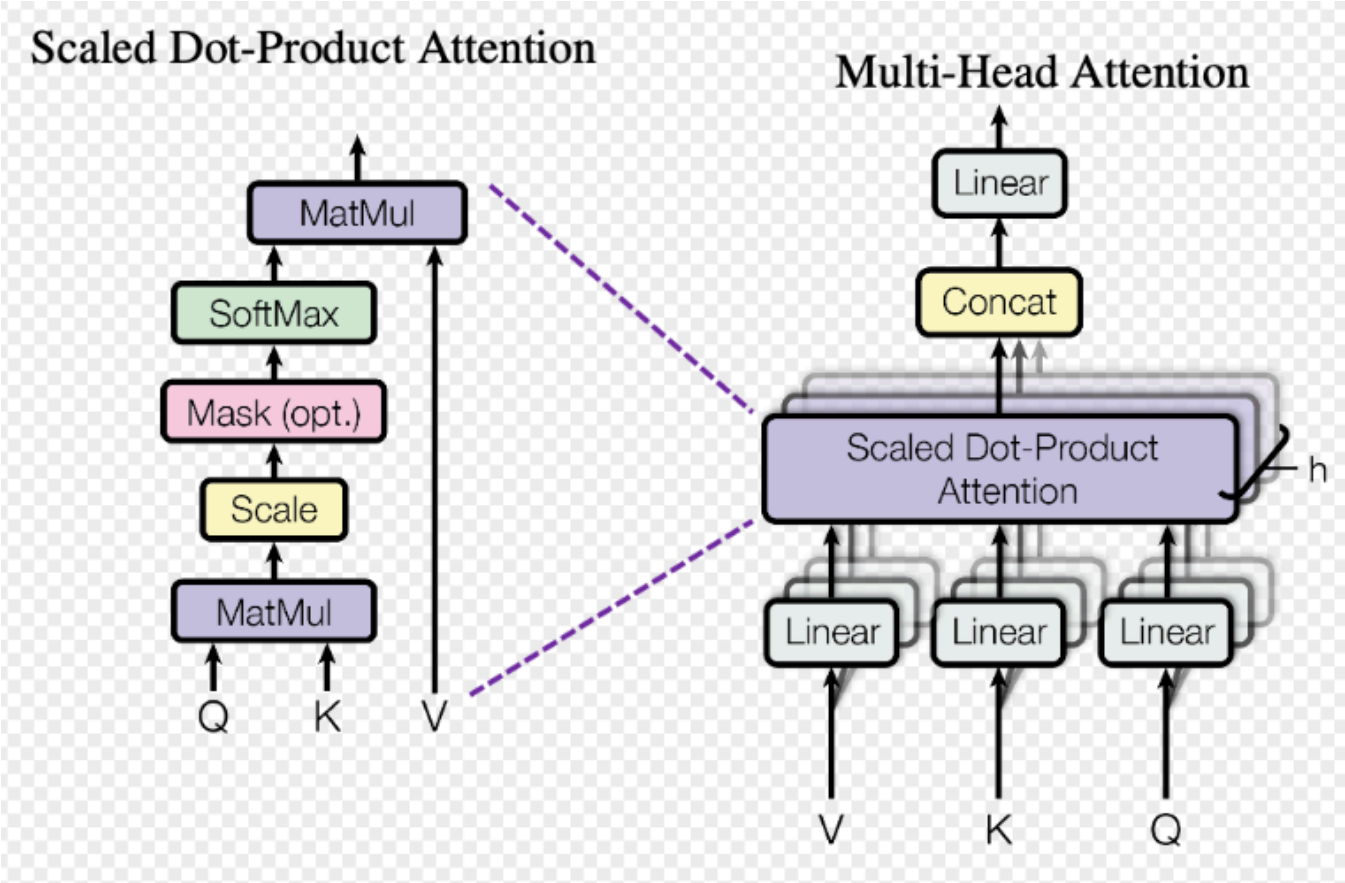

[该图片展示了缩放点积注意力流程以及下文的多头注意力]

四. 多头注意力

我们希望模型可以基于多个相同的注意力机制学习到不同的行为, 然后将不同的行为作为知识组合起来.

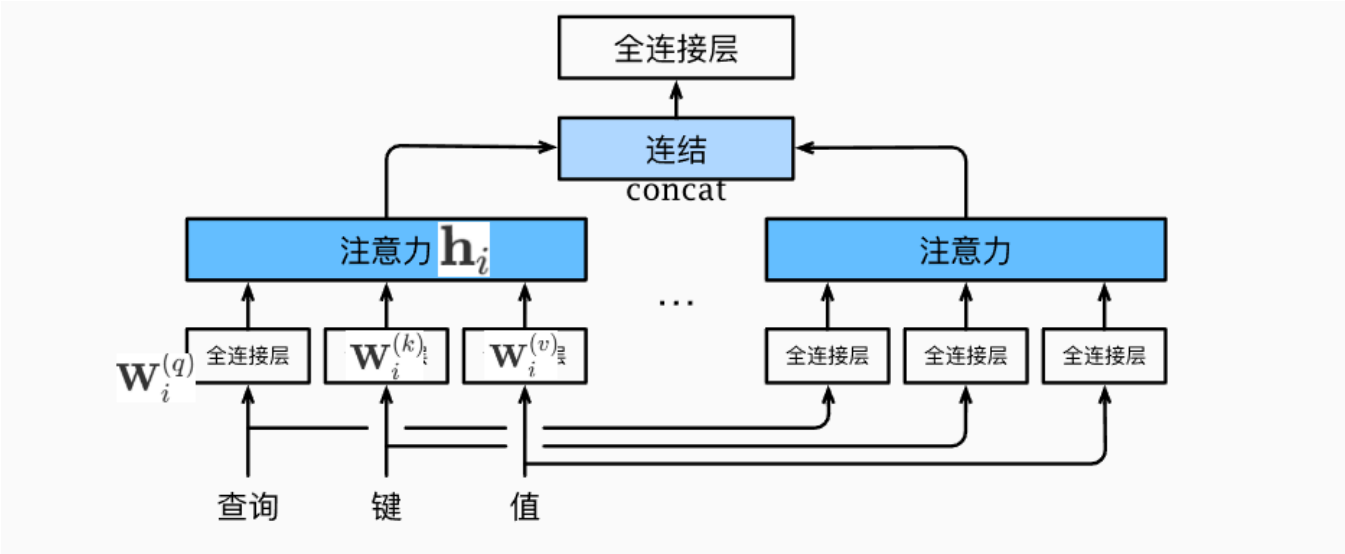

1. 数学模型

给定查询$\mathbf{q} \in \mathbb{R}^{d_q}$、键$\mathbf{k} \in \mathbb{R}^{d_k}$和值$\mathbf{v} \in \mathbb{R}^{d_v}$，每个*注意力头* $\mathbf{h}_i$（$i = 1, \ldots, h$）的计算方法为：

$$\mathbf{h}_i = f(\mathbf{q}\mathbf{W}_i^{(q)}, \mathbf{k}\mathbf{W}_i^{(k)}, \mathbf{v}\mathbf{W}_i^{(v)}) \in \mathbb{R}^{1 \times p_v},$$

其中，相较于一个注意力头, 多头注意力模型**多出的可学习的参数**包括$\mathbf{W}_i^{(q)} \in \mathbb{R}^{d_q \times p_q}$、$\mathbf{W}_i^{(k)} \in \mathbb{R}^{d_k \times p_k}$和$\mathbf{W}_i^{(v)} \in \mathbb{R}^{d_v \times p_v}$，以及代表注意力汇聚的函数$f$, f可以是前面的加性注意力机制, 或缩放点积注意力机制

多头注意力的输出需要经过另一个线性转换，它对应着h个头连结(Concat)后的结果，因此其可学习参数是$\mathbf{W}_o \in \mathbb{R}^{hp_v \times p_o}$：

$$\left[\mathbf{h}_1 \ldots \mathbf{h}_h\right] \mathbf{W}_o \in \mathbb{R}^{p_o}$$

基于这种设计，**每个头都可能会关注输入的不同部分**，可以表示比简单加权平均值更复杂的函数。

2.Multi-head实现

这里选择**缩放点积注意力**作为每个注意力头. 为了**避免计算代价和参数代价的大幅增长**, 设定$p_q = p_k = p_v = p_0/h$ [实际上是一个单头注意力, 只是把Q, K, V划分(特征维度上)成num_heads个空间并行计算]

```python
class MultiHeadAttention(nn.Module):
    """多头注意力"""
    def __init__(self, key_size, query_size, values_size, num_hiddens,
                 num_heads, dropout, bias=False, **kwargs):
        super(MultiHeadAttention, self).__init__(**kwargs)
        self.num_heads = num_heads
        self.attention = DotProductAttention(dropout) # 使用缩放点积注意力
        self.W_q = nn.Linear(query_size, num_hiddens, bias=bias)
        self.W_k = nn.Linear(key_size, num_hiddens, bias=bias)
        self.W_v = nn.Linear(values_size, num_hiddens, bias=bias)
        self.W_0 = nn.Linear(num_hiddens, num_hiddens, bias=bias)

    def forward(self, queries, keys, values, valid_lens):
        # queries, keys, values 的 形状:
        # (batch_size, 查询或者键值对的个数, query_size/key_size/values_size)
        # valid_lens 的形状:
        # (batch_size,) 或(batch_size, 查询的个数)
        # 经过变换后, 输出的queries, keys, values的形状:
        # (batch_size*num_heads, 查询或者键值对的个数, num_hiddens/num_heads)
        queries = transpose_qkv(self.self.W_q(queries), self.num_heads)
        keys = transpose_qkv(self.W_k(keys), self.num_heads)
        values = transpose_qkv(self.W_v(values), self.num_heads)

        if valid_lens is not None:
            # 在轴0, 将第一项(标量或者矢量)复制num_heads次,
            # 然后如此复制第二项, 然后诸如此类.
            valid_lens = torch.repeat_interleave(
                valid_lens, repeats=self.num_heads, dim=0)

            # output的形状: (batch_size*num_heads, 查询的个数, num_hiddens/num_heads)
            output = self.attention(queries, keys, values, valid_lens)

            # 拼接
            # output_concat的形状为: (batch_size, 查询的个数, num_hiddens)
            output_concat = transpose_output(output,self.num_heads)

            return self.W_o(output_concat)
```

五. 自注意力机制

将词元序列输入到注意力汇聚中, **每个查询都会关注其他所有的键值对并生成一个注意力权重**, 这称为**自注意力(self-attention)**

1. 自注意力

给定一个词元序列$x_1, x_2, ..., x_n[x_i \in R^d]$, 该序列的自注意力输出长度相同的序列$y_1, y_2, .., y_n$, 其中:

$$y_i = f(x_i, (x_1, x_1), ..., (x_n, x_n)) \in R^d$$

[自注意力中, Q, K, V来自同一输入序列X]

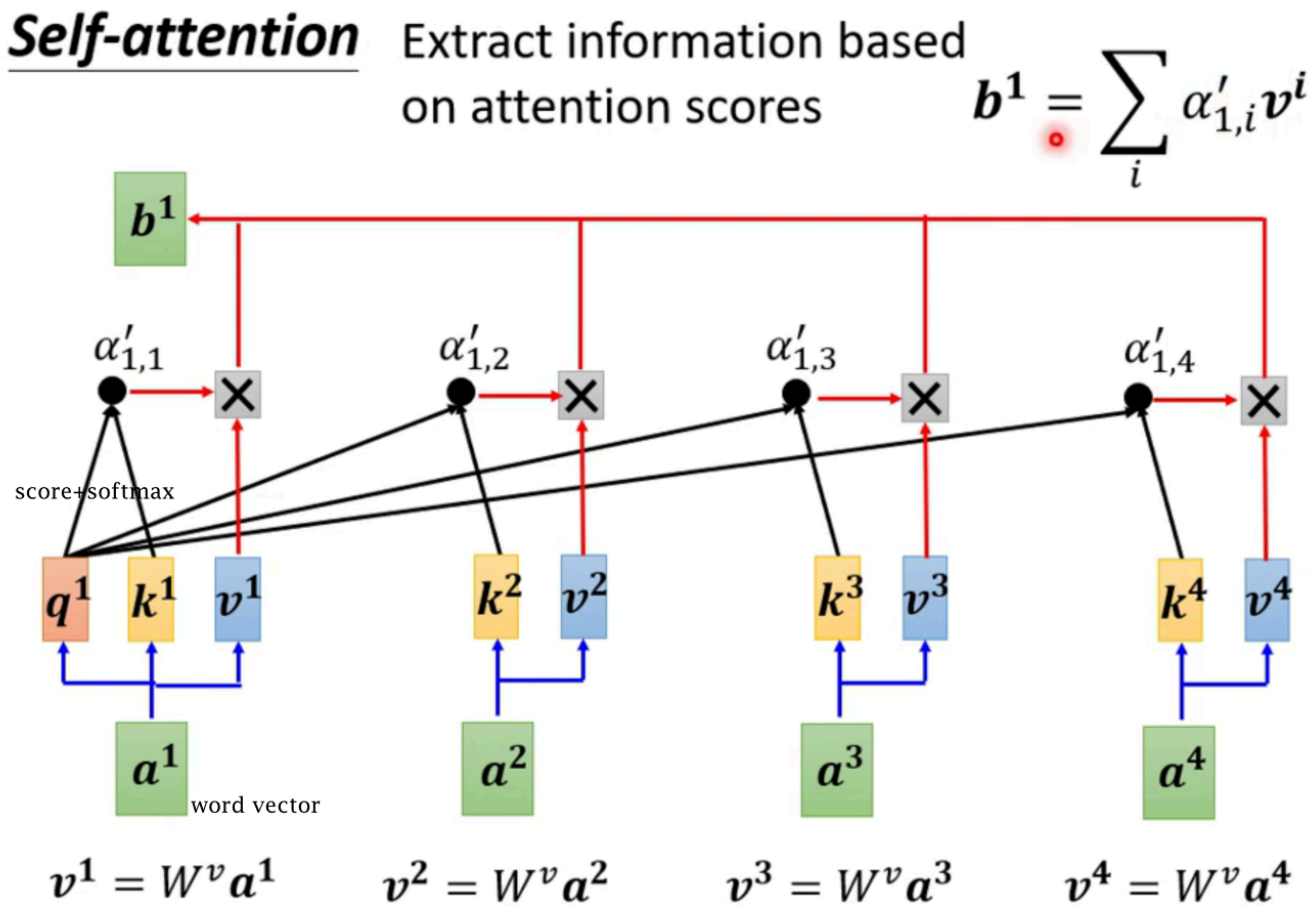

2. 自注意力 vs rnn

目标: 将由n个d维词元组成的序列映射到另一个长度相等的序列

1. 相较于*循环神经网络*的对词元序列的顺序操作, $O(n)$个顺序操作, *卷积神经网络*和*自注意力的计算*只需要$O(1)$个顺序操作, 具有**并行计算**的优势
2. 自注意力的计算, 每个词元都**通过自注意力直接连接到任何其他词元**, 任意的序列位置组合之间的路径为$O(1)$, 能更轻松学习序列中的远距离依赖关系.
3. 自注意力的计算复杂性为$O(n^2d)$(参考缩放点积注意力), 因此在很长的序列中计算会很慢

3. 位置编码

自注意力为了**并行运算**放弃了**顺序操作**, 为了使用序列中的顺序信息, 通过**在输入**表示添加**位置编码(positional encoding)来注入位置信息**
输入词元序列$X \in R^{n\times d}$, 位置编码使用形状相同的位置嵌入矩阵 $P \in R^{n\times d}$输出$X+P$, 矩阵第i, 第$2j$列和第$2j+1$列上的元素为:

$$p_{i,2j} = \sin(\frac{i}{10000^{2j/d}})$$
$$p_{i,2j+1} = \cos(\frac{i}{10000^{2j/d}})$$

```
class PositionalEncoding(nn.Module):
    """位置编码"""
    def __init__(self, num_hiddens, dropout, max_len=1000):
        super(PositionalEncoding, self).__init__()
        self.dropout = nn.Dropout(dropout)

        self.P = torch.zeros((1, max_len, num_hiddens)) # 维度要和X相同
        X = torch.arange(max_len, dtype=torch.float32.reshape(-1,1))
        / torch.pow(10000,
        torch.arange(0, num_hiddens, 2, dtype=torch.float32) / num_hiddens)
        # 该步骤相当于两层for循环

        self.P[:, :, 0::2] = torch.sin(X)
        self.P[:, :, 1::2] = torch.cos(X)

    def forward(self, X):
        X = X + self.P[:, :X.shape[1], :].to(X.device)
        return self.dropout(X)
```

在位置嵌入矩阵P中, 行代表词元在序列中的位置, 列代表位置编码的不同维度, **每一行的相邻两**

列属于一个词元的位置编码的两个维度

六. Attention机制计算过程

Attention 机制计算过程大致可以分成三步:

1. 信息输入

用 $X = [x_1, x_2, \ldots x_n]$ 表示输入权重向量

2. 计算注意力分布 α

通过评分函数计算分数,softmax计算注意力权重,

$$\alpha_i = softmax(score(k_i, q)) = softmax(score(x_i, q))$$

α_i为注意力概率分布, $score(x_i, q)$为注意力评分函数, 常见的有如下几种:

- 加性模型: $s(x_i, q) = v^T tanh(Wx_i + Uq)$
- 点积模型: $s(x_i, q) = x_i^T q$
- 缩放点积模型: $s(x_i, q) = x_i^T q / \sqrt{d_k}$
- 双线性模型: $s(x_i, q) = x_i^T W q$

3. 信息加权平均

注意力分布α_i来解释在上下文查询 q_i 时，第 i 个信息受关注程度。

$$att(q, X) = \sum_{i=1}^{N} \alpha_i V_i$$